

Methoden des Maschinellen Lernens

VL 06: Naive Bayes und Entscheidungsbäume

Matthias König, Philipp Viertel

FH Bielefeld Campus Minden

31. März 2021

1 Wahrscheinlichkeitstheorie

- Bedingte Wahrscheinlichkeiten
- Bayes Regel
- Unabhängige Ereignisse
- Klassifikation mit Naive Bayes

2 Entscheidungsbäume

- ID3 Algorithmus
- Beispiel
- Eigenschaften des ID3
- Random Forest
- Boosting

Definition:

- Ein Element (world) ω
- Ein Ereignis (sample space) Ω
- Eine Wahrscheinlichkeit $P(\omega)$
- Eine Proposition ϕ

- Ein Ereignis ist eine endliche Menge an Elementen

$$\Omega = [\omega_1, \dots, \omega_n]$$

- An dieser Stelle werden wir nur diskrete Ereignisse mit endlicher Anzahl an Elementen betrachten
- Für Elemente in einem Ereignis gilt:
 - ▶ Ausschließend (exclusive); nur ein Ereignis kann eintreten
 - ▶ Ausschöpfend (exhaustive); es muss mindestens ein Ereignis eintreten

- Beispielsweise das Ereignis "Wurf eines sechsseitigen Würfels" A :
$$A = [1, 2, 3, 4, 5, 6]$$
- Jedes Element eines Ereignisses hat eine Wahrscheinlichkeit $P(\omega)$ wobei:
 - ▶ Die Wahrscheinlichkeit für ein Element liegt zwischen 0 und 1
 - ▶ Die Summe aller Elemente in einem Ereignis ist 1

$$0 \leq P(\omega) \leq 1 \forall \omega ; \sum_{\omega \in \Omega} P(\omega) = 1$$

- Bei einem nicht manipulierten Würfel hat jedes Element die gleiche Wahrscheinlichkeit aufzutreten

$$P(\omega) = \frac{1}{6} \forall \omega \in A$$

- In der Wahrscheinlichkeitstheorie sucht man meistens nach Gruppen von Elementen, diese nennt man Proposition

$$\text{Für jede Proposition } \phi \text{ gilt, } P(\phi) = \sum_{\omega \in \phi} P(\omega)$$

bei gleich-verteilten Wahrscheinlichkeiten auch:

$$P(\phi) = \frac{|\phi|}{|\Omega|} = \frac{\text{Anzahl der Fälle in denen } \phi \text{ hält}}{\text{Anzahl der möglichen Fälle}}$$

- Hier am Beispiel der Proposition "Wurf einer geraden Zahl"

$$\text{"geradeZahl" } A = [2, 4, 6] ; P(A) = \left(\frac{1}{6}\right) + \left(\frac{1}{6}\right) + \left(\frac{1}{6}\right) = \frac{1}{2}$$

- Außerdem lässt sich ein Zusammenhang zwischen der Wahrscheinlichkeit einer Proposition und seiner Negation herleiten:

$$\begin{aligned} P(\neg A) &= \sum_{\omega \in \neg A} P(\omega) \\ &= \sum_{\omega \in \neg A} P(\omega) + \sum_{\omega \in A} P(\omega) - \sum_{\omega \in A} P(\omega) \\ &= \sum_{\omega \in \Omega} P(\omega) - \sum_{\omega \in A} P(\omega) \\ &= 1 - P(A) \end{aligned}$$

- Somit lässt sich die Proposition "Wurf einer ungeraden Zahl" $\neg A$ folgendermaßen lösen:

$$P(\neg A) = 1 - P(A) = \frac{1}{2}$$

Russell and Norvig [2010]

Bedingte Wahrscheinlichkeiten

- Bisher nur unbedingte Wahrscheinlichkeit (keine weiteren Informationen verfügbar)
- Jetzt hinzuziehen von bereits eingetretenen Propositionen
- Das Eintreten von Proposition von A nachdem Proposition B bereits eingetreten ist:

$$P(A|B) = \frac{P(A,B)}{P(B)}$$


- Dies hält solange $P(B) > 0$

- Hieraus abgeleitet die Kettenregel:

$$P(A, B) = P(A|B)P(B)$$

$$\begin{aligned} P(A_1, A_2, \dots, A_n) &= P(A_n, \dots, A_2, A_1) \\ &= P(A_n|A_{n-1}, \dots, A_1)P(A_{n-1}, \dots, A_1) \\ &= P(A_n|A_{n-1}, \dots, A_1)P(A_{n-1}|A_{n-2}, \dots, A_1)P(A_{n-2}, \dots, A_1) \\ &= \dots \\ &= P(A_n|A_{n-1}, \dots, A_1) \dots P(A_2|A_1)P(A_1) \\ &= \prod_i P(A_i|A_1, \dots, A_{i-1}) \end{aligned}$$

- Wichtig für Sprachmodellierung (Wahrscheinlichkeit für Wortfolge)



Beispiel eines Entscheidungsbaums. Serlo [2018]

Diagnose beim Zahnarzt

- $P(A, B) = P(B, A)$ = Wahrscheinlichkeit, dass A und B gleichzeitig auftreten (Verbundwahrscheinlichkeit)

	Zahnschmerzen	$\neg$ Zahnschmerzen
Karies	0.04	0.06
$\neg$ Karies	0.01	0.89

- Die Wahrscheinlichkeit, dass ein beliebiger Patient Karies hat beträgt:
 $P(K, Z) = 0.04$ oder $P(K, \neg Z) = 0.06$ also eine Gesamtwahrscheinlichkeit von 10%

- Fragt man einen Patient ob dieser Zahnschmerzen hat, kann man dieses Wissen in die Prognose einfließen lassen

	Zahnschmerzen	$\neg$ Zahnschmerzen
Karies	0.04	0.06
$\neg$ Karies	0.01	0.89

$$P(\text{karies}|\text{zahnschmerzen}) = \frac{P(K,Z)}{P(Z)} = \frac{0.04}{0.04+0.01} = 0.8$$

$$P(\text{karies}|\neg\text{zahnschmerzen}) = \frac{P(K,\neg Z)}{P(\neg Z)} = \frac{0.06}{0.06+0.89} = 0.063$$

Einschub Popositions Notation

- Variablen heißen Zufallsvariable (Zahnschmerzen), diese beginnen immer mit einem Großbuchstaben
- Jede Zufallsvariable hat eine Domäne aus möglichen Werten $\{2, 3, 4\}$, $\{\text{true}, \text{false}\}$, $\{\text{sonne}, \text{regen}, \text{schnee}\}$
- die Größe einer Domäne muss nicht zwingend endlich sein
- Propositionen können mit den Mitteln der Aussagenlogik verknüpft werden

$$P(karies | \neg \text{zahnschmerzen} \wedge \text{jugendlich}) = 0.1$$

- Anstelle von:

$$P(Wetter = sonnig) = 0.6$$

$$P(Wetter = regen) = 0.1$$

$$P(Wetter = wolkig) = 0.29$$

$$P(Wetter = schnee) = 0.01$$

- wird abgekürzt mit:

$$P(Wetter) = \langle 0.6, 0.1, 0.29, 0.01 \rangle$$

Marginalisierung und Conditionierung

	Zahnschmerzen	$\neg$ Zahnschmerzen	Summe
Karies	0.04	0.06	0.1
$\neg$ Karies	0.01	0.89	0.9
Summe	0.05	0.95	1

- $P(K) = P(K, Z) + P(K, \neg Z)$
- Seien $B_1, \dots, B_n$ Elementarereignisse mit $\sum_i B_i = \Omega$.
- Dann ist

$$\begin{aligned} P(A) &= \sum_i P(A, B_i) \text{ (Marginalisierung)} \\ &= \sum_i P(A|B_i)P(B_i) \text{ (Conditionierung)} \end{aligned}$$

	Zahnschmerzen	$\neg$ Zahnschmerzen	Summe
Karies	0.04	0.06	0.1
$\neg$ Karies	0.01	0.89	0.9
Summe	0.05	0.95	1

- Mit diesen Regeln können durch das Aufsummieren ihrer Wahrscheinlichkeiten, Variablen aus der Funktion entfernt werden

Bayes Regel

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- $P(A|B)$ nennt man auch “Posterior“ oder “A-posteriori-Wahrscheinlichkeit“
Wie wahrscheinlich ist A , wenn B eingetreten ist?
- $P(B|A)$ nennt man auch “Likelihood“:
Mutmaßung für das Auftreten von B , gegeben A , keine Wahrscheinlichkeit
- $P(A)$ nennt man auch “Prior“ oder “A-priori-Wahrscheinlichkeit“:
Die Wahrscheinlichkeit für A ohne weiteres Wissen
- $P(B)$ ist die Evidenz und wird als Normierungsfaktor verwendet.

- In der Medizin sucht man i.d.R. die Ursache für beobachtete Symptome:

$$P(\text{Ursache}|\text{Symptome}) = \frac{P(\text{Symptome}|\text{Ursache})P(\text{Ursache})}{P(\text{Symptome})}$$

- Aus der A-priori-Wahrscheinlichkeit für bestimmte Krankheiten und der Likelihood der Symptome (wie wahrscheinlich sind Symptome, gegeben einer Krankheit) kann man die Wahrscheinlichkeit für das Vorliegen einer Erkrankung gegeben bestimmter Symptome berechnen.

Beispiel

- Bei Meningitis wird oft ein steifer Hals beobachtet: $P(S|M) = 0.8$
- Eine von 10000 Personen hat Meningitis: $P(M) = 0.0001$
- Eine von 10 Personen hat einen steifen Hals: $P(S) = 0.1$

Ich habe einen steifen Hals. Habe ich Meningitis?

$$P(M|S) = \frac{P(S|M)P(M)}{P(S)} = \frac{0.8 \times 0.0001}{0.1} = 0.0008 = 0.08\%$$

- Bei einem steifen Hals liegt die Wahrscheinlichkeit, an Meningitis erkrankt zu sein, bei nur 0.08%. Also kein Grund zur Sorge in diesem Fall.

Weiteres Beispiel

Beispiel aus Wolfgang Ertel: "Grundkurs Künstliche Intelligenz", Springer Vieweg, 2016 (Seite 148) Ertel [2013]

- Alarmanlage meldet jeden Einbruch mit einer Sicherheit von 99%
- Wahrscheinlichkeit für Einbruch: 0.1%
- Wird auch von Tieren o.ä. ausgelöst, Alarm-Wahrscheinlichkeit 10%

Wie wahrscheinlich ist ein Einbruch, wenn der Alarm ertönt?

- Gegeben: $P(A) = 0.1$, $P(E) = 0.001$, $P(A|E) = 0.99$
- Gesucht: $P(E|A)$

$$P(E|A) = \frac{P(A|E)P(E)}{P(A)} = \frac{0.99 \times 0.001}{0.1} = 0.0099 = 0.99\%$$

- Bei Ertönen des Alarms liegt die Wahrscheinlichkeit für einen Einbruch bei nur knapp 1 Prozent. Diese Alarmanlage ist vielleicht nicht sehr hilfreich...

- Frage: Wie wahrscheinlich ist ein Alarm ohne Einbruch, also $P(A|\neg E)$?
- Mit Marginalisierung:

$$P(A) = P(A|E)P(E) + P(A|\neg E)P(\neg E)$$

$$\begin{aligned} 0.1 &= 0.99 \times 0.001 + P(A|\neg E) \times (1 - 0.001) \\ &= 0.00099 + P(A|\neg E) \times 0.999 \end{aligned}$$

$$P(A|\neg E) = 0,0991$$

In knapp 10 Prozent der Fälle wird der Alarm ohne Einbruch ausgelöst...

Unabhängige Ereignisse

$$\begin{aligned}P(\text{Zahnschmerzen}, \text{Regen}) &= \\P(\text{Regen}|\text{Zahnschmerzen})P(\text{Zahnschmerzen}) \\P(\text{Regen}|\text{Zahnschmerzen}) &= ? = P(\text{Regen})\end{aligned}$$

- Zwei Ereignisse A und B sind unabhängig, wenn

$$P(A|B) = P(A)$$

- Daraus folgt:

$$P(A, B) = P(A|B)P(B) = P(A)P(B)$$

Bedingte Unabhängigkeit:

- X und Y sind bedingt unabhängig (gegeben Z), wenn

$$P(X|Y, Z) = P(X|Z) \text{ bzw. } P(Y|X, Z) = P(Y|Z)$$

- Daraus folgt:

$$P(X, Y|Z) = P(X|Y, Z)P(Y|Z) = P(X|Z)P(Y|Z)$$

Klassifikation mit Naive Bayes

Zum besseren Verständnis der folgenden Folien, lesen Sie bitte aus dem Buch “Grundkurs Künstliche Intelligenz“ von Wolfgang Ertel, das Kapitel 8.7.

Klassifikation mit Naive Bayes

- Naive Bayes ist eine Verallgemeinerung der Bayes Regel

$$P(H|D_1, \dots, D_n) = \frac{P(D_1, \dots, D_n|H)P(H)}{P(D_1, \dots, D_n)}$$

- Ist “naiv“ in der Annahme, dass alle Daten bedingt unabhängig sind:

$$P(D_1, \dots, D_n|H) = P(D_1|H) \cdot \dots \cdot P(D_n|H) = \prod_i P(D_i|H)$$

- Beobachtung: $P(D_1, \dots, D_n)$ für alle Hypothesen $h \in H$ gleich

- Naive Bayes Klassifikator bzw. MAP(“Maximum a Posteriori“)

$$\begin{aligned} h_{MAP} &= \operatorname{argmax}_{h \in H} P(h|D_1, \dots, D_n) \\ &= \operatorname{argmax}_{h \in H} P(h) \prod_i P(D_i|h) \end{aligned}$$

- Naive Bayes: Wähle die plausibelste Hypothese, die von den Daten unterstützt wird.

Bayes'sches Lernen

$$\begin{aligned}h_{MAP} &= \operatorname{argmax}_{h \in H} P(h|D_1, \dots, D_n) \\ &= \operatorname{argmax}_{h \in H} P(h) \prod_i P(D_i|h)\end{aligned}$$

Training: Bestimme die Wahrscheinlichkeiten aus Trainingsdaten S

- Für jede Klasse h

- ▶ Schätze $P(h) = \frac{|S(h)|}{|S|}$

- ▶ Für jedes Attribut D_i und jede Ausprägung $x \in D_i$:

- ★ Schätze $P(D_i = x|h) = \frac{|S_{D_i}(x) \cap S(h)|}{|S(h)|}$

Klassifikation: Wähle wahrscheinlichste Klasse h_{MAP} für Vektor x

- $h_{MAP} = \operatorname{argmax}_{h \in H} P(h) \prod_{x \in x} P(x|h)$

Tafelbeispiel

Nr.	Himmel	Lufttemp.	Wassertemp	Wind	Schwimmen?
1	sonnig	warm	warm	windstill	ja
2	sonnig	kalt	warm	stürmisch	nein
3	sonnig	warm	warm	brise	ja
4	bewölkt	kalt	kalt	windstill	nein
5	regen	kalt	warm	windstill	ja

- Eingabe: Merkmalsvektor '(sonnig, kalt, warm, windstill)'
- Gesucht: $P(\text{ja})$, $P(\text{nein})$,
 $P(\text{Himmel=sonnig}|\text{ja})$, $P(\text{Himmel=sonnig}|\text{nein})$, ...

Wähle Klasse

$$h_{MAP} = \operatorname{argmax}_{h \in \{\text{ja}, \text{nein}\}} \\ P(h) \cdot P(\text{Himmel=sonnig}|h) \cdot P(\text{Luft=kalt}|h) \\ \cdot P(\text{Wasser=warm}|h) \cdot P(\text{Wind=windstill}|h)$$

Naivität in Naive Bayes

Theoretisch: Unabhängigkeit der Attribute oft nicht gegeben

- $P(D_1, \dots, D_n|H) \neq \prod_i P(D_i|H)$
- A-posteriori-Wahrscheinlichkeiten oft unrealistisch nah an 1 oder 0

Praxis: Dennoch häufig sehr gute Ergebnisse

- Wichtig:

$$\operatorname{argmax}_{h \in H} P(h)P(D_1, \dots, D_n|h) = \operatorname{argmax}_{h \in H} P(h) \prod_i P(D_i|h)$$

- Solange die Maximierung die selben Ergebnisse liefert, müssen die konkreten Schätzungen/Werte nicht exakt stimmen...

Wenn Attribute nicht (bedingt) unabhängig sind, kann sich der NB verschätzen, d.h. es kommt dann u.U. zu einer höheren Fehlerrate, da bestimmte Eigenschaften in der Trainingsmenge zu hoch gewichtet werden.

Probleme mit Floating Point Underflow

- MAP berechnet Produkt mit vielen Termen
- Problem: Bei kleinen Zahlen kann Floating Point Underflow auftreten!
- Lösung: Logarithmus maximieren (Produkt geht in Summe über)

- Erinnerung: $\log(x \cdot y) = \log(x) + \log(y)$ und Logarithmus streng monoton

$$\begin{aligned} h_{MAP} &= \operatorname{argmax}_{h \in H} P(h|D_1, \dots, D_n) \\ &= \operatorname{argmax}_{h \in H} P(h) \prod_i P(D_i|h) \\ &= \operatorname{argmax}_{h \in H} [\log(P(h)) + \sum_i \log(P(D_i|h))]\end{aligned}$$

Laplace-Schätzer

- Problem: Attributsausprägung für bestimmte Klasse nicht in Trainingsmenge:
 - ▶ Bedingte Wahrscheinlichkeit ist 0
 - ▶ Produkt gleich 0
- Lösung: “Laplace-Schätzer“ (auch “Laplace-Glättung“)

- Statt $P(D_i = x|h) = \frac{|S_{D_i}(x) \cap S(h)|}{|S(h)|}$
- nutze $P(D_i = x|h) = \frac{|S_{D_i}(x) \cap S(h)| + m \cdot p_i}{|S(h)| + m}$
- mit m : frei wählbarer Faktor
- p_i : A-priori-Wahrscheinlichkeit für $P(D_i = x|h)$

“virtuelle“ Trainingsbeispiele (m ist die Zahl der virtuellen Trainingsbeispiele)

Grenzen von Naive Bayes

- Ungeeignet zum Lernen von Regeln wie:
 Wenn: (Wassertemp = warm $\wedge$ Wind = $\neg$ stürmisch) dann:
 Schwimmen
- Mit Naive Bayes nicht möglich, da angenommen wird das alle Attribute unabhängig sind

Finden der korrekten Wahrscheinlichkeitsverteilung

Gaussian:

$$P(x_i | y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i - \mu_y)^2}{2\sigma_y^2}\right)$$

Multinomial: Gegeben sei:


- Parameter der Verteilung: $\theta_y = (\theta_{y1}, \dots, \theta_{yn})$ für $\forall_y$
- Abhängige Wahrscheinlichkeit: $\theta_{yi} = P(x_i | y)$
- Anz. Feature in y : $N_{y_i} = \sum_{x \in T} x_i$
- Anz. Features gesamt: $N_y = \sum_{i=1}^n N_{y_i}$
- $\alpha \begin{cases} \alpha \geq 0, \text{ verhindert Nullwahrscheinlichkeiten} \\ \alpha = 1, \text{ Laplace-Glättung} \\ \alpha < 1, \text{ Lidstone-Glättung} \end{cases}$

$$\hat{\theta}_{yi} = \frac{N_{yi} + \alpha}{N_y + \alpha n}$$

Bernoulli:

$$P(x_i | y) = P(i | y)x_i + (1 - P(i | y))(1 - x_i)$$

Entscheidungsbäume




- Eingabe: Instanz $x \in X$
 - ▶ Instanz wird durch Vektor von Attributen repräsentiert

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

- ▶ Wird auch Merkmalsvektor genannt
- Ausgabe: Klasse $y \in Y$
 - ▶ z.B. (akzeptiert, abgelehnt), (Spam, kein Spam), (schwimmen, nicht schwimmen)
 - ▶ Auch Zielattribut genannt


Entscheidungsbäume sind gut geeignet wenn:

- Instanzen aus Attribut Wert-Paaren mit diskreten Werten bestehen
- Man Kategorien lernen möchte und keine kontinuierliche Funktion $\Rightarrow$ Transformation zu kategorischen Variablen mit **Entropy-based Binning**
- Man nur unvollständige oder leicht fehlerhafte Trainingsdaten besitzt



- Knoten testen ein Attribut
- Zweige entsprechen den Werten eines Attributs
- Blätter weisen Instanzen einer Kategorie zu

Terminologie



Vorgehen:

- Am stärksten klassifizierendes Attribut finden
- Stärkstes Attribut als Wurzel setzen
- Zweig für jeden möglichen Wert des Attributs erstellen
- Rekursiv für jeden Zweig mit der Untermenge der zu klassifizierenden Daten wiederholen bis die Klasse des Zweigs eindeutig ist

Entropie

Gegeben:

- X = Datensatz
- $|Y|$ = Anzahl der Klassen
- p_c = Anzahl der Instanzen in X die der Klasse c angehören
- $H(X)$ = Entropie des Datensatzes

$$H(X) = - \sum_{c=1}^Y p_c \log_2 p_c$$

Informationgain

Gegeben:

- X = Datensatz
- $H(X)$ = Entropie im Datensatz oder einer Untermenge davon
- X_v = Untermenge von X für die x den Wert v hat
- $|X|$ = Mächtigkeit X
- $|X_v|$ = Mächtigkeit von X_v
- $\text{Gain}(X, A)$ = Erwartete Reduzierung der Entropie bei bekanntem Attribut A

$$\text{Gain}(X, A) = H(X) - \sum_{v \in A} \frac{|X_v|}{|X|} H(X_v)$$

Beispieldatensatz

Wir wollen lernen bei welchen Wetterbedingungen draußen gespielt wird:

outlook	temp.	humidity	windy	play
sunny	hot	high	false	no
sunny	hot	high	true	no
overcast	hot	high	false	yes
rainy	mild	high	false	yes
rainy	cool	normal	false	yes
rainy	cool	normal	true	no
overcast	cool	normal	true	yes
sunny	mild	high	false	no
sunny	cool	normal	false	yes
rainy	mild	normal	false	yes
sunny	mild	normal	true	yes
overcast	mild	high	true	yes
overcast	hot	normal	false	yes
rainy	mild	high	true	no

- Schritt 1: Berechnen der Gesamtentropie
14 Instanzen. 5 mal “play=no“ und 9 mal “play=yes“

$$H(X) = -\frac{9}{14} \log_2 \frac{9}{14} - \frac{5}{14} \log_2 \frac{5}{14} = 0.940286$$

- Schritt 2: Für jedes Attribut den Datensatz nach Werten des Attributs unterteilen und hierfür die Entropie berechnen

A : “windy = false“:

8 Instanzen, 6 mal “play=yes“ + 2 mal “play=no“

$$H(X_{false}) = -\frac{6}{8} \log_2 \frac{6}{8} - \frac{2}{8} \log_2 \frac{2}{8} = 0.8112781$$

A : “windy = true“:

6 Instanzen, 3 mal “play=yes“ + 3 mal “play=no“

$$H(X_{true}) = -\frac{3}{6} \log_2 \frac{3}{6} - \frac{3}{6} \log_2 \frac{3}{6} = 1$$

- Schritt 3: Aus den Teilentropien und der Gesamtentropie den Informationgain ermitteln

$$Gain(X, windy) = H(X) - \frac{|X_{false}|}{|X|} H(X_{false}) - \frac{|X_{true}|}{|X|} H(X_{true})$$

$$Gain(X, windy) = 0.940286 - \frac{8}{14} * 0.8112781 - \frac{6}{14} * 1 = 0.04812703$$


- Diese Schritte werden für alle Attribute wiederholt:

$$Gain(X, outlook) = 0.247$$


$$Gain(X, temperature) = 0.029$$

$$Gain(X, humidity) = 0.152$$

- Outlook als Wurzel setzen




- Rekursiv für jeden Wert des Attributs wiederholen



$$\text{Gain}(X, \text{windy}) = 0.020$$

$$\text{Gain}(X, \text{temperature}) = 0.571$$

$$\text{Gain}(X, \text{humidity}) = 0.971$$



Eigenschaften des ID3 Algorithmus

- Auswahl der Knoten nach höchstem Informationsgewinn über den gesamten Datensatz
- Robust gegenüber Unregelmäßigkeiten
- Keine vollständige Suche (nicht zwingend der optimale Baum)
- Flache Bäume werden bevorzugt
- Neigt zu Overfitting

Reduktion in Varianz

- Bisherige Betrachtung von Algorithmen für kategorische Ziel-Variablen
- Dieser Algorithmus nutzt eine niedrige Varianz als Teilungskriterium wie folgt:
 - Berechnung der Varianz für jeden Knoten
 - Berechnung der Varianz für jede Teilung als gewichteter Durchschnitt jeder Knotenvarianz

$$\text{Varianz} = \frac{\sum (x - \hat{x})^2}{n}$$

Vermeidung von Overfitting

Zwei mögliche Parameter zur Modellierung um Overfitting zu vermeiden

- Die Höhe der Trees limitieren
- Tree Pruning

Ohne diese Verfahren erreicht ein DT (Decision Tree) fälschlicherweise eine Genauigkeit von 100% $\Rightarrow$ Warum?

Frei wählbare Parameter zur Definition eines DT:

- ① Minimum Samples For Node Split
- ② Minimum Samples For Terminal Node
- ③ Maximum Depth of Tree
- ④ Maximum Number of Terminal Nodes
- ⑤ Maximum Features For Split

Pruning

- ① Ausbreitung des DT bis zu einer tiefen Ebene
- ② Entfernen der Blätter Bottom-up die im Vergleich zur Spitze negative Werte zurückgeben
- ③ Betrachtung des gesamten IG (Information Gain), bspw. $-10 + 20 = +10$ nachdem die erste Teilung negativ war, d.h. positiver Pfad

Entropy-based binning

- Auch Diskretisierung genannt: Kann Rauschen und nicht-Linearität reduzieren sowie ungünstige Variablen und Ausreißer identifizieren
- Nutzt einen Teilungsansatz, bei dem intuitiv gesehen alle Werte in ein Behälter zu einem Label korrespondieren
- Teilung mit maximalen Informationsgewinn

Besteht aus folgenden Schritte - ähnlich zum ID3:

- 1 Berechnung der Entropie des Ziels
- 2 Berechnung der Entropie des Ziels aus einem Behälter
- 3 Berechnung des Information Gain... probiere andere Intervalle und vergleiche IG

Bagging (Bootstrap Aggregating)

- Idee: Es werden verschiedene Teilmengen aus den Trainingsdaten genommen und auf Grundlage dieser Daten verschiedene Decision Trees trainiert.
- Jeder Decision Tree gibt als Ergebnis ein “vote“ ab.
- Der Durchschnitt aller votes ist das Endergebnis.

Random Forest

- Spezielle Form von bagging
- ① Setze Anzahl der Fälle im Trainingsdatensatz auf N und nehme Proben **zufällig** mit **Ersetzung** $\Rightarrow$ Trainingsdatensatz für den Baumwachstum
- ② Wähle zufällig eine Konstante $m < M$ (Eingabevariablen) für jeden Knoten aus M um den Knoten basierend aus dem Besten der m Variablen zu splitten.
- ③ Jeder Baum ist bis auf die tiefste Ebene ausgebaut und es findet kein Pruning statt
- ④ Vorhersage neuer Daten durch Aggregation der N Bäume
 - $\left\{ \begin{array}{l} \textit{Klassifikation} : \textit{Mehrheitsvotum} \\ \textit{Regression} : \textit{Durchschnitt} \end{array} \right.$

Präziser für eine Vorhersage der unbekannten Eingabe x :

- **Regression:**

$$\hat{f}_{rf}^B(x) = \frac{1}{B} \sum_{b=1}^B T_b(x)$$

Beweis: Random Forests funktioniert

$$\begin{aligned} \text{Var}\left(\frac{1}{B}\right) \sum_{i=1}^B T_i(x) &= \frac{1}{B^2} \sum_{i=1}^B \sum_{j=1}^B \text{Cov}(T_i(x), T_j(x)) \\ &= \frac{1}{B^2} \sum_{i=1}^B (\sum_{j \neq i}^B \text{Cov}(T_i(x), T_j(x)) + \text{Var}(T_i(x))) \\ &= \frac{1}{B^2} \sum_{i=1}^B \boxed{((B-1)\sigma^2 \cdot p + \sigma^2)} \\ &= \frac{B(B-1)p\sigma^2 + B\sigma^2}{B^2} \\ &= \frac{B(B-1)p\sigma^2}{B} \frac{\sigma^2}{B} \\ &= p\sigma^2 - \frac{p\sigma^2}{B} + \frac{\sigma^2}{B} \\ &= \boxed{p\sigma^2} + \boxed{\sigma^2 \frac{1-p}{B}} \end{aligned}$$

Boosting

Beschreibt die Umwandlung schwacher zu starker Klassifikatoren (GBM, XGboost)

Ermitteln der besten Verteilung:

- 1 Der **Basislerner** betrachtet alle Verteilungen und weist jeder Beobachtung die selbe Gewichtung zu
- 2 Im Falle eines **Fehlers** beim Basislerner: Höhere Priorität auf die Beobachtung mit dem Fehler und setzen den nächsten Basislerner
- 3 **Iteration**: Bis Limit des Basislernalers erreicht ist oder eine höhere Genauigkeit erzielt wird.
- 4 Kombination und Wahl des Labels analog zum Bagging

weiterführende Recherche:

- NB mit kontinuierlichen Attributen
 - ▶ Diskretisierung der Attribute
 - ▶ Dichtefunktionen
- Entscheidungsbäume optimieren
 - ▶ Pruning
- C4.5 Algorithmus

Vielen Dank für Eure Aufmerksamkeit!

Wolfgang Ertel. *Grundkurs Künstliche Intelligenz: Eine praxisorientierte Einführung*. Springer Fachmedien Wiesbaden, 3. Aufl. 2013 edition, 2013. ISBN 9783834816771.

Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Prentice Hall, 3 edition, 2010.

Serlo. Bedingte wahrscheinlichkeit, March 2018. URL <https://de.serlo.org/mathe/1973/bedingte-wahrscheinlichkeit>.