

Aufgabe 1

a) $0,35/1 = 35\%$

b) $0,35 * 0,35 * 0,35 * 0,65 = \text{ca. } 0,028 = 2,8\%$

c) $0,2275 + 0,0525 = 0,28 = 28\%$

d) $0,1625 / (0,07 + 0,1625) = 0,699 = 69,9\%$

e) $(0,2275 + 0,0525) / (0,2275 + 0,0525 + 0,26 + 0,2275) = 0,3648 = 36,5\%$

Aufgabe 2

	Positiv	¬Positiv	Summe
Krank	0.0095	0.0005	0.01
¬Krank	0.0198	0.9702	0.99
Summe	0.0293	0.9707	1

W'keit Positiv & Tatsächlich krank:

$$P(\text{krank} | \text{positiv}) = P(K,P) = 0.0095$$

$$P(P) = 0.0293$$

$$0.0095 / 0.0293 = 0.3242 = 32,42\%$$

Aufgabe 3

Beutel 1: 60x R | 40x B

Beutel 2: 30x R | 70x B

$$P(B1 | \text{Rot}) = 0.5 * 0.6 = 0.3$$

$$P(B1 | \text{Blau}) = 0.5 * 0.4 = 0.2$$

$$P(B2 | \text{Rot}) = 0.5 * 0.3 = 0.15$$

$$P(B2 | \text{Blau}) = 0.5 * 0.7 = 0.35$$

$$P(B1 | \text{Rot}) = P(\text{Rot} | B1) * P(B1) / P(\text{Rot}) = (0.3 * 0.5) / 0.6 = 0.25 = 25\%$$

Aufgabe 4

- Naive Bayes ist naiv, da bedingte Wahrscheinlichkeiten von Merkmalen auf Grundlage von den individuellen Wahrscheinlichkeiten der Merkmale berechnet wird. Hierdurch besteht eine direkte Abhängigkeit der bedingten Wahrscheinlichkeiten von den individuellen Wahrscheinlichkeiten, welche im praktischen Zusammenhang wahrscheinlich niemals eintreten werden.
- <groß, leicht, lang>: Mit dem gegebenen Trainingsdatensatz nicht klassifizierbar
 - <klein, schwer, kurz>: männlich, da es ein direktes Matching mit einem Merkmalsvektor aus dem Trainingsdatensatz gibt (Datensatzreihe 7)
 - <mittel, leicht, lang>: weiblich, da es ein direktes Matching mit einem Merkmalsvektor aus dem Trainingsdatensatz gibt (Datensatzreihe 9)

Aufgabe 5

Der Laplace Schätzer ist das Ergebnis eines Laplace-Experiments.

$$P(E) = |E| / |\Omega|$$

E: Wahrscheinlichkeit des Ereignisses E

Ω : Anzahl aller möglichen Ereignisse

Die Wahrscheinlichkeit eines Ereignisses E eines Laplace-Experiments ist gleich dem Quotienten aus den Mächtigkeiten des Ereignisses E (der Anzahl der Elemente aus dem Ergebnis E) und des Ergebnisraums Ω (der Anzahl aller möglichen Ergebnisse).

Aufgabe 6

a)

- a) Schritt: **Auswählen des Attributes mit dem höchsten Informationsgewinn**
Betrachte alle Attribute (Merkmale) des Datensatzes und bestimme, welches Attribut die Daten am besten klassifiziert.
- b) Schritt: **Anlegen eines Knotenpunktes mit dem Attribut**
Sollten die Ergebnisse unter diesem Knoten eindeutig sein (1 unique value), speichere es in diesem Knotenpunkt und springe zurück.
- c) Schritt: **Rekursive Fortführung dieses Prozesses**
Andernfalls zerlege die Daten jedem Attribut entsprechend in n Untermengens (subsets), und wiederhole diese Schritte für jede der Teilmengen.

Aufgabe 7

a)

1. **Anwendbarkeit sowohl auf diskrete als auch auf kontinuierliche Attribute** – Enthalten die Datensätze beispielsweise eine reelle Größe als eines der Merkmale, so werden die Merkmalswerte in diskrete Intervalle eingeordnet.
 2. **Anwendbarkeit auf Trainingsdaten mit fehlenden Attributswerten** – Unter Anwendung von C4.5 können nicht verfügbare Merkmalswerte als unbekannt (?) markiert werden. Unbekannte Werte werden bei der Berechnung des Information Gain einfach ignoriert.
 3. **Mögliche Kostengewichtung der Attribute** – Aufwändig zu bestimmenden Merkmalen kann eine höhere Kostengewichtung zugeordnet werden. Merkmale mit hohen Kostengewichtungen werden tendenziell weiter unten im Entscheidungsbaum als Verzweigungen angeordnet, sodass für weniger Klassifizierungen dieses Merkmal überhaupt bestimmt werden muss.
 4. **Stutzen (Pruning) des Entscheidungsbaumes nach dessen Erstellung** – Um die Anzahl der möglichen Ergebnisklassen der Klassifizierung zu verringern, schneidet C4.5 lange Äste ab. Dies verhindert außerdem Überanpassung an die Trainingsdaten.
- b) Die Information gain ratio verhindert, dass der Decision tree Attribute mit einer großen Anzahl von unterschiedlichen Werten berücksichtigt. Dadurch wird ein Nachteil des information gain, nämlich das Overfitting an das Training Set durch eine Vielzahl an unterschiedlichen Merkmalsausprägungen, gelöst.

Aufgabe 8

Welches Problem wollen Sie mittels ML bearbeiten?

E-Commerce (E-Bay) Preisverläufe vorhersagen und Preis-Leistungs-Index erstellen.

Was für Daten nutzen Sie oder benötigen Sie?

Vergangene und aktuelle Verkaufsdaten der Inserate auf Verkaufsplattformen.

Was wollen Sie erreichen und wie wollen Sie es erreichen?

Vorhersage des zu erwartenden Preises und der Zeit bis zum Verkauf durch Regression.

Außerdem: Aufstellen von Ähnlichkeitsmetriken für Inserate, um mithilfe von Clustering einen Preis-Leistungs-Index der Inserate zu berechnen.

Wie testen Sie Ihre Lösung?

Evaluierung der Vorhersagen mit bestehenden historischen und aktuellen Daten.